

우도함수와 베이지 정리로 중심으로 바라본 베이지안 최적화

수학과 소학회 MCS (Mathematics & Computer Science)

최보경, 이영진, 연성민, 이수정, 이윤지, 황유희

지도 교수 : 이영섭 교수님

베이지안 최적화란

베이지안 최적화는 실험 비용이 커서 여러 번의 실험을 진행할 수 없는 연구에서 주어진 데이터를 이용하여 함수를 추정하여 최댓값을 도출해낼 수 있는 입력값을 효율적으로 찾아내는 최적화 기법이다. 이때 최댓값이란, 어떤 문제를 해결할 수 있는 조건일때 나오는 최고의 결과이다.

이는 현재 기계학습, 로봇공학, 바이오/의약 분야 등 다양한 산업과 연구 분야에서 폭넓게 활용되고 있다.

베이지안 최적화 과정

1. Gaussian Process Regression

: 함수를 추정하기 위해 아래의 세 단계를 거친다.

1) mean function (평균함수)

: 함수 전체의 기본적인 형태를 초기 추정하는데 사용되는 것으로, 데이터를 보기 이전에 함수의 형태를 미리 추정한다.

일반적인 경우 : $\mu_0(x) = \mu$ * μ : 상수

추정하고자 하는 함수의 정보를 알 때 : $\mu_0(x) = \mu + \sum_{i=1}^p \beta_i \Psi_i(x)$

* μ : 상수 β_i : 회귀계수 $\Psi_i(x)$: 매개변수화된 함수

2) Kernel (커널) - Gaussian kernel (가우시안 커널)

: 커널 함수는 입력값 x, x' 와 사이의 상관관계를 정의하는 함수로, 모델이 학습할 함수의 성질(부드러움, 주기성, 길이 척도 등)에 대한 사전적인 가정을 반영한다.

Gaussian Process에서는 공분산 함수의 역할을 하며, 관측되지 않은 점들의 함수값이 얼마나 비슷할지 표현한다.

$$\Sigma_0(x, x') = \alpha_0 \exp(-\|x - x'\|^2)$$

* α_0 : 분산의 크기를 조절하는 상수

* $\exp(-\|x - x'\|^2)$: 입력값 간 거리에 따라 공분산을 조절하는 항

3) Choosing a Hyperparameter (하이퍼파라미터 추정)

: 커널의 하이퍼파라미터들을 추정하는 과정으로,

이를 추정하기 위한 방법으로는 MLE와 MAP가 있다.

이때, 커널의 하이퍼파라미터에는 길이 척도, 분산 등이 있다.

2. Acquisition function (획득함수)

: 추정한 함수의 최댓값을 추정하기 위해 실험해볼 입력값들을 추려내는 단계이다.

우도함수와 MLE

1. 우도함수 (Likelihood)

: 주어진 데이터가 특정 모델에서 발생할 가능성으로,

임의의 하이퍼파라미터 η 에 대해 관측 데이터 $f(x_{1:n})$ 가 나올 확률

$$P(f(x_{1:n}) | \eta)$$

* $f(x_{1:n})$: 관측된 데이터 η : 하이퍼파라미터 벡터

2. MLE (Maximum Likelihood Estimate)

임의의 하이퍼파라미터 η 에 대해 관측된 데이터 $f(x_{1:n})$ 가 나올 확률에서 가장 큰 확률을 갖도록 하는 하이퍼파라미터를 선택하는 것

$$\hat{\eta} = \arg \max_{\eta} P(f(x_{1:n}) | \eta)$$

베이지 정리와 MAP

1. MAP (Maximum A Posteriori)

: 사후확률이 최대가 되도록 하는 η 를 추정하는 방식으로, 우도함수에 사전확률을 곱해 사전정보를 반영함.

$$\hat{\eta} = \arg \max_{\eta} P(\eta | f(x_{1:n})) = \arg \max_{\eta} P(f(x_{1:n}) | \eta) P(\eta)$$

* $P(\eta | f(x_{1:n}))$: 사후확률 $P(\eta)$: 사전확률

2. 베이지 정리 (Bayes' Theorem)

: 베이지 정리를 이용하여 MAP 식을 아래의 과정을 통해 변형함.

$$P(\eta | f(x_{1:n})) = \frac{P(f(x_{1:n}) | \eta) \cdot P(\eta)}{\sum_{\eta'} P(f(x_{1:n}) | \eta') \cdot P(\eta')} \approx P(f(x_{1:n}) | \eta) \cdot P(\eta)$$

MLE와 MAP 비교

목표 : 자동차의 속도를 최대한 높일 수 있는 타이어의 압력 찾기

관측 데이터 : 타이어 압력과 자동차 속도에 대한 주행 데이터 (3회)

최대압력인 35psi에서 자동차의 속도가 최대가 됨

사전 정보 : 자동차 타이어의 압력이 35psi보다 높으면 속도 감소

1) MLE

: 오로지 관측 데이터만 고려하는 방법

→ 관측 데이터에서 최대 압력였던 35psi에서 자동차의 속도가 가장 빨랐기에, 압력이 증가할수록 자동차의 속도는 증가할 것

2) MAP

: 관측 데이터와 사전정보를 모두 고려하는 방법

→ 타이어의 압력이 35psi를 넘으면 속도가 감소하므로

압력이 35psi일때, 자동차는 최대속도를 낼 것이라고 예측

실제 모델로 증명하는 우도함수와 사후확률

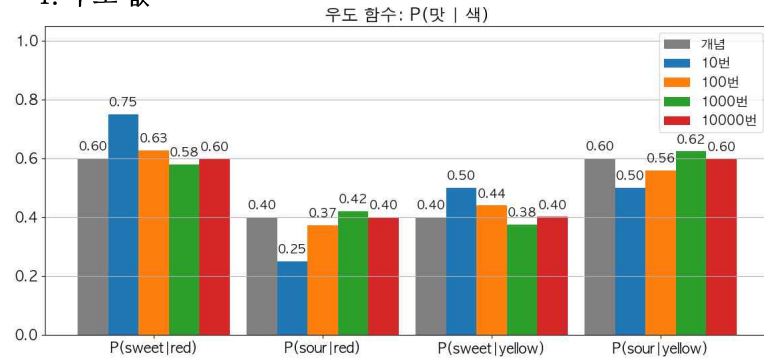
종합 젤리 봉투 안에 아래의 비율로 젤리가 들어있다고 가정하자.

빨간색 젤리 : 노란색 젤리 = 7 : 3


빨간색 젤리 중 단 맛 : 신 맛 = 6 : 4

노란색 젤리 중 단 맛 : 신 맛 = 4 : 6

1. 우도 값



2. 사후확률 값



3. 결론

- 시행횟수를 늘려 젤리를 10,000번까지 뽑았을 때, 실제 값과 이론적인 개념 값이 거의 같아지는 것을 확인할 수 있다.
- 해당 사례에서는 우도 값보다 사후확률 값이 더 낮다는 것을 알 수 있다.

4. 첨부 - 코드

젤리는 파이썬 코드를 이용해서 뽑았다.

```
import random
from collections import Counter # 결과 집계를 위한

# 젤리 종류와 확률, 딕셔너리 사용
jelly_types = {
    ("red", "sweet"): 0.42, ("red", "sour"): 0.28, ("yellow", "sweet"): 0.12,
    ("yellow", "sour"): 0.18
}

# 젤리 뽑기 시뮬레이션 함수 정의
def simulate_jelly_draws(n):
    # 조합 리스트와 각 조합의 확률
    combinations = list(jelly_types.keys())
    probabilities = list(jelly_types.values())

    # 랜덤 뽑기
    results = random.choices(combinations, weights=probabilities, k=n)

    # 결과 집계
    counts = Counter(results)

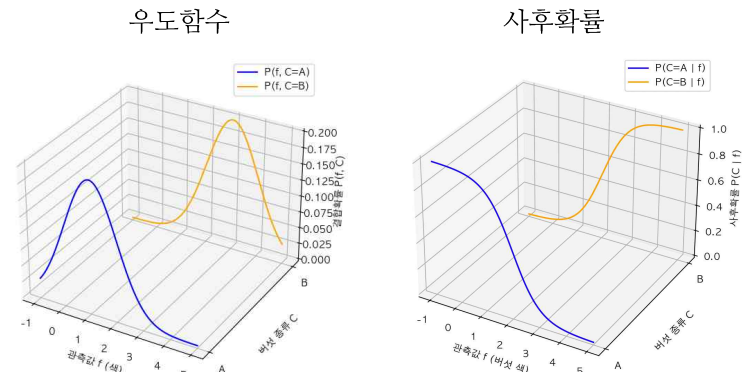
    # 출력
    print(f"\n중 {n}번의 뽑기 결과:")
    for combo in combinations:
        color, taste = combo
        count = counts[combo]
        print(f"{color.capitalize()} & {taste.capitalize()}: {count}개")

if __name__ == "__main__":
    while True:
        try:
            n = int(input("\n뽑을 젤리 개수를 입력하세요: "))
            if n > 0:
                simulate_jelly_draws(n)
            else:
                print("0 이상의 숫자를 입력해주세요.\n")
                continue
        except ValueError:
            print("숫자를 입력해주세요.\n")
```

예시로 보는 우도함수와 사후확률


버섯의 밝기 정보를 이용하여 등산 중에 발견한 버섯이 독버섯인지 식용버섯인지 맞추어보자. 버섯의 밝기를 f 라고 하고 버섯의 종류를 C 라고 하자. 이때, 가정은 아래와 같다.

각 버섯 별로 하이퍼파라미터가 고정되어 있다고 가정하고, 이때의 하이퍼파라미터는 버섯의 종류를 의미하도록 한다.



비교를 위해

각각 3차원 형태인 우도함수와 사후확률의 그래프를
관측값 축에서 바라봤을때 얻어지는
평면 상의 그래프가 아래와 같다고 하자.



결론

관측값 $f(= \text{버섯의 색})$ 이 대략 $[2, 2.69]$ 일때
우도함수를 기준으로 보면, 발견한 버섯이 B일 확률이 높는데,
사후확률을 기준으로 보면, A일 확률이 높다.

이렇듯 우도함수로 판단하는 것과 사후확률로 판단하는 것의 결과는 다를 수 있다. 우도함수는 사전 정보를 반영하지 않기 때문에 소극적인 판단을 할 수 있고, 사후확률은 사전 정보를 반영하기에 보다 안정적인 판단을 할 수 있다.